

[模式识别大作业]

大学生生成式 AI 使用频率分类模型

基于 1781 份问卷的三分类建模与关键因素分析

姓名 · 学号

2026.06

[背景] — 研究背景与核心问题

生成式 AI 已深度融入大学生的学习与科研。

然而，使用频率因人而异——有人日均数十次，有人从未接触。

理解「谁在用、用多少、为什么」，对教育引导与产品优化都有价值。

[问题]

哪些因素，决定了一名大学生使用生成式 AI 的频率高低？

[数据]

数据概况

1781

份有效问卷

64


个特征（原 78 列）

3

类使用频率

[分布]


低频 8.1%



中频 73.8%



高频 18.0%



[预处理] — 数据清洗与特征工程

排除的列

- 总分、Q15 总体情况
- Q16 该不该使用（近零方差 95.9%）
- 学校、序号、所用时间（元数据）
- Q17、Q18 开放文本题
- 注意力检测题（34.9% 未通过）

编码方式

One-Hot

学历 / 专业 / 年级 / 课程偏好


数值型

重要度 0—100% · 功能排序 · Likert 1—5

原编码 / 聚合

性别 · 产品使用二值列 → product_count


[方法] — 技术路线




评估指标：Macro F1 为主 · 辅以每类 Precision / Recall 与混淆矩阵

[实验] 01 多模型对比 · SVM 最优

- SVM Macro F1 = 0.4988 , 六模型最优
- Logistic 回归次之 (0.4951)
- KNN / 决策树最弱 (< 0.40)
- 低频组仅 8.1% 样本, 整体分类难度大




[实验] 02 5 折交叉验证 · 稳定性





- **Logistic 回归最稳定**
- CV Mean = 0.5134 , 方差最小
- SVM 紧随其后, 表现稳健
- 各模型折间波动可控, 无过拟合

[实验] 03 SVM 混淆矩阵 · 低频组识别难



- 中频（ 73.8% ）识别最准
- 低频仅 145 人，大量被误判为中频
- 高频次之，与中频存在混淆
- → 类别不平衡是核心难点

[调优] — 超参数网格搜索




[RF] $n_estimators \approx 200$ 、 $max_depth \approx 20$ 最佳

[SVM] $C = 10$ 后性能趋于稳定

[因子] 01 三种方法交叉验证

跨方法特征重要性对比




三方法共识

[RF] 随机森林 Gini 重要性

[Perm] 排列重要性

[SHAP] Shapley 值

[因子] 02 SHAP 深度分析




- **product_count 影响最显著**
- 高取值正向推高使用频率
- 文本生成功能使用排第二
- 性别、文心一言为次级驱动

[因子] 03 共识排名 · Top 5 关键因素

排名	关键特征	平均排名
1	使用产品数量 product_count	1.3
2	文本生成功能使用	3.0
3	文心一言使用	4.0
4	性别	7.7
5	ChatGPT 使用	8.3

[可视化] — PCA 降维可视化



- PC1 解释方差 17.4%
- PC2 解释方差 5.8%
- 三类用户在降维空间存在重叠
- → 使用频率受多因素共同作用

[结论] 关键发现

01

产品数量最强

product_count 与频率相关 $r = 0.364$ ，居三方法之首

02

文本生成功能

是区分使用频率高低的重要行为信号

03

性别显著

性别对使用频率存在系统性影响

04

SVM 最优但受限

Macro F1 = 0.4988，受低频样本 8.1% 限制

[局限] 局限与展望

局限性

- 低频样本仅 8.1% ，少数类难识别
- Q14 注意力题 34.9% 未通过
- PCA 投影下三类存在重叠

展望

- 扩充低频样本、重采样策略
- 引入特征选择与交互项
- 尝试梯度提升 / 神经网络

感谢聆听 · 欢迎提问